

RECONOCIMIENTO DE OBJETOS CON PANDAS Y NUMPY

FELIPE DE JESUS MENDEZ RUIZ

INTELIGENCIA ARTIFICIAL

03 de abril del 2025

INDICE

Unidad 1: introducción a la inteligencia artificial

- 1.1 Evolución histórica de la inteligencia artificial
- 1.2 Concepto de la inteligencia artificial
- 1.3 Características de la inteligencia artificial
- 1.4 Campo de aplicación

Unidad 2: representación y búsquedas

- 2.1 Espacio de estados
- 2.2 Representación del conocimiento
- 2.3 Mecanismos de búsqueda

Unidad 3: Lenguajes especiales de inteligencia artificial

- 3.1 Lisp y Prolog
- 3.2 Otros lenguajes

Unidad 4: Conocimientos teóricos generales de la inteligencia artificial

- 4.1 Aprendizaje
- 4.2 sistemas expertos

Evolución histórica de la inteligencia artificial

La historia de la IA se remonta a la década de 1950, cuando los pioneros en el campo comenzaron a vislumbrar la posibilidad de crear máquinas capaces de imitar la inteligencia humana. Alan Turing, considerado el padre de la informática, desencadenó esta era con su concepto de la máquina universal, sentando las bases para la creación de algoritmos y procesadores que más tarde serían esenciales para la IA.

1956: John McCarthy y el Nacimiento del Término Inteligencia Artificial

En la primera conferencia sobre inteligencia artificial en el Dartmouth College, John McCarthy acuñó el término inteligencia artificial. Ese mismo año, Allen Newell, J.C. Shaw y Herbert Simon desarrollan el Logic Theorist, el primer programa de software operativo de IA.

Los años 60 y 70: La era de la optimización de algoritmos

Durante los años 60 y 70, se produjo un crecimiento exponencial en el campo de la IA. Se desarrollaron algoritmos más sofisticados, como el algoritmo de búsqueda en profundidad, que permitió a las máquinas realizar tareas más complejas.

1967: Rosenblatt y el Perceptrón Mark 1

Frank Rosenblatt construye el Perceptrón Mark 1, el primer ordenador basado en una red neuronal que aprende mediante ensayo y error. Aunque, un año después, el libro Perceptrons de Marvin Minsky y Seymour Papert genera debate sobre el futuro de las redes neuronales.

Con la llegada de los años 80, la IA se embarcó en una nueva fase de desarrollo, centrada en el aprendizaje automático.

1997: El Triunfo de Deep Blue en el Ajedrez

En un hito histórico, Deep Blue de IBM derrota al campeón mundial de ajedrez, Garry Kasparov, en una partida y su revancha, demostrando la capacidad de las máquinas para superar a los maestros humanos en juegos estratégicos.

En las últimas dos décadas, hemos presenciado avances extraordinarios en la IA que han transformado la vida cotidiana.

La IA no sólo ha impactado el ámbito tecnológico, sino que también ha dejado una huella significativa en la sociedad.

Diferentes generaciones de IA y su impacto en la sociedad

Asistentes virtuales y reconocimiento de voz: Facilidad en la interacción con la tecnología

Los asistentes virtuales, como Siri de Apple, Alexa de Amazon y Google Assistant, son ejemplos populares de aplicaciones de IA que han revolucionado la forma en que interactuamos con la tecnología.

Diagnóstico médico asistido por IA: Aumento de la precisión y la velocidad

Los algoritmos de aprendizaje automático pueden analizar grandes cantidades de datos médicos, como imágenes de resonancia magnética y resultados de pruebas de laboratorio, para detectar patrones y anomalías que podrían pasar desapercibidos para los profesionales de la salud.

Educación: Personalización del aprendizaje

Los sistemas de IA pueden analizar el rendimiento académico y los patrones de aprendizaje de los estudiantes para identificar áreas de fortaleza y debilidad, lo que permite una personalización del aprendizaje según las necesidades individuales de cada estudiante.

Transporte: Impulso en la movilidad inteligente

Los vehículos autónomos utilizan algoritmos de aprendizaje automático y sensores para percibir el entorno y tomar decisiones en tiempo real, sin intervención humana.

Seguridad y vigilancia: Detección y mejora en la prevención del delito

Los sistemas de vigilancia basados en IA pueden analizar imágenes y videos en tiempo real para detectar comportamientos sospechosos y actividades delictivas.

Definición y enfoques de la IA

La inteligencia artificial (IA) es un conjunto de tecnologías que permiten que las computadoras realicen una variedad de funciones avanzadas, incluida la capacidad de ver, comprender y traducir lenguaje hablado y escrito, analizar datos, hacer recomendaciones y mucho más.

Enfoque humano

La primera definición dentro de AI abarca los sistemas que pueden pensar como un humano. Si los sistemas pueden aprender y resolver problemas como una persona, entonces entran en esta categoría. Haugeland definió esto en 1985 como máquinas con mentes. Hellman dijo en 1978 que esta categoría es la automatización de actividades que asociamos con el pensamiento humano.

Enfoque racional

El segundo conjunto de categorías para los sistemas AI miden su capacidad de desempeñarse de forma racional; esto difiere del comportamiento humano porque las personas no son racionales todo el tiempo. Existen, de nuevo, 2 formas de ver AI: los sistemas pueden pensar de forma racional o actuar de forma racional.

Diferencias entre AI débil e IA fuerte

AI Débil

Los términos débil y fuerte son otra forma de distinguir los tipos de sistemas AI. AI Débil probablemente se le puede referir de forma más apropiada como AI Angosta o Artificial Narrow Intelligence. AI se enfoca en realizar tareas específicas, como Siri de Apple, Alexa de Amazon o un vehículo autónomo de Google.

AI Fuerte

AI Fuerte se compone de 2 tipos de AI: Artificial General Intelligence (AGI) y Artificial Super Intelligence (ASI). AGI es un sistema autoconsciente, es decir, que tiene una

consciencia. Puede resolver problemas e incluso planear para el futuro. ASI es un sistema que sobrepasa las capacidades humanas.

Características de la inteligencia artificial

Aprendizaje automático.

Esta característica permite a las máquinas aprender de los datos y mejorar su desempeño con el tiempo sin necesidad de ser programadas explícitamente para cada tarea.

Razonamiento y resolución de problemas.

Esta característica se utiliza en una gran variedad de aplicaciones, desde la optimización de procesos empresariales hasta el diseño de nuevos productos.

Procesamiento del lenguaje natural.

La capacidad de comprender y generar lenguaje humano es una de las características más importantes de la inteligencia artificial, ya que permite a las máquinas interactuar con los humanos de forma más natural.

Hay dos maneras en las que se puede utilizar la visión artificial para tomar decisiones como recuento, clasificación o aprobación y rechazo de artículos. Los sistemas basados en reglas siguen instrucciones paso a paso programadas por el usuario para interpretar imágenes y tomar decisiones.

Sistemas basados en reglas

La visión artificial tradicional basada en reglas utiliza reglas de probabilidad específicas para tomar decisiones sobre una imagen. Los ingenieros de visión programan las reglas con un profundo conocimiento de la mejor combinación de técnicas para obtener el resultado deseado.

Deep Learning

Deep Learning utiliza la IA para potenciar los sistemas de visión artificial usando ejemplos para entrenar el software con imágenes etiquetadas hasta que pueda hacer distinciones por sí solo.

Edge Learning

Edge Learning es otro tipo de IA, optimizado para satisfacer las necesidades de la automatización industrial. Viene preentrenado para resolver los tipos de problemas que generalmente enfrenta la automatización industrial.

Comparación de sistemas basados en reglas e impulsados con IA

La decisión entre los sistemas de Deep Learning y Edge Learning basado en reglas se reduce principalmente al tipo de aplicación que se implemente.

Las herramientas de visión basadas en reglas son efectivas en distintas tareas especializadas con objetivos muy consistentes como ubicación, medición y orientación.

Edge Learning se destaca en tareas repetibles con objetivos moderadamente consistentes.

Deep Learning brilla cuando se buscan defectos complejos o se analizan imágenes con variación significativa.

Aplicaciones en industria, salud, educación, finanzas y seguridad

Una de las aplicaciones más destacadas de la IA en las fábricas es la mejora de la gestión de la cadena de suministro. La IA puede analizar los datos de producción y predicciones de demanda para ayudar a las empresas a tomar decisiones informadas sobre cuánto y cuándo producir. Esto ayuda a minimizar los costos al mantener los niveles de inventario adecuados y a reducir el desperdicio.

La IA puede acelerar el proceso de descubrimiento de medicamentos, al analizar millones de compuestos y predecir cuáles podrían ser efectivos contra una enfermedad en particular. También ayuda a personalizar tratamientos basados en la genética de cada paciente, mejorando la efectividad y reduciendo efectos secundarios.

Los educandos y los docentes utilizan sin duda la IA con diferentes fines: para crear, para escribir, para programar y mucho más. La IA proporciona nuevas vías que permiten explorar y buscar ayuda sobre determinados temas, aunque también proporciona accesos rápidos.

En la mayoría de los exámenes estandarizados los nuevos sistemas de IA generativa con grandes modelos lingüísticos obtienen mejores puntuaciones que la media de los estudiantes y, a menudo, se sitúan en el décimo o incluso en el primer rango porcentual. Esto es algo que obliga a los sistemas escolares a replantearse los modos de evaluación normales y que impulsará innovaciones en la manera de medir el aprendizaje. En otras palabras, se trata de replantear la manera en que aprendemos y enseñamos y, en consecuencia, cómo se enseña a los educandos y qué es lo que éstos deberán priorizar

La inteligencia artificial (IA) en finanzas ayuda a obtener estadísticas para el análisis de datos, la medición del rendimiento, las predicciones y la previsión, los cálculos en tiempo real, el servicio de atención al cliente, la recuperación inteligente de datos y mucho más. Es un conjunto de tecnologías que permite que las organizaciones de servicios financieros comprendan mejor mercados y clientes, analicen y aprendan de los recorridos digitales y, al mismo tiempo, interactúen de forma similar a la inteligencia humana y las interacciones a gran escala.

La IA puede ayudar a proteger los datos confidenciales en entornos de nube híbrida identificando automáticamente los datos ocultos, monitorizando las anomalías en el acceso a los datos y alertando a los profesionales de la ciberseguridad sobre las amenazas a medida que se producen.

Uso de la IA en visión por computadora y reconocimiento de objetos

La visión por computadora o visión computarizada hace referencia a un grupo de tecnologías o herramientas que permiten a los equipos captar imágenes del mundo real, procesarlas y generar información a través de ellas (análisis).

Dicho de otra manera, la visión por computador es una propiedad de ciertas tecnologías que permiten a los equipos computarizados ver.

Esto ha hecho posible el diseño de maquinaria industrial y colaborativa de gran flexibilidad, capaces de tomar decisiones inteligentes con base en su entorno, a niveles imposibles de igualar por el ojo humano.

La detección de objetos es una tecnología puntera en aprendizaje automático y el aprendizaje profundo que permite a los ordenadores identificar y localizar con precisión objetos dentro de imágenes o vídeos. Pertenece a una rama de la inteligencia artificial denominada Visión por computador.

Los programas informáticos de detección de objetos pretenden reproducir los complejos procesos de la visión humana mediante diversos datos de entrenamiento y la orquestación de complejos algoritmos: las máquinas perciben y comprenden el mundo visual con un nivel de precisión y sofisticación antes reservado exclusivamente a la percepción humana.

La Computer Vision es uno de los campos que evoluciona más rápidamente. En el centro de su rápido progreso se encuentra el importante papel de la detección de objetos. Este artículo pretende ofrecerle una visión general de los principales conceptos esenciales para comprender los mecanismos de detección de objetos por una máquina.

Espacio de estados

En la representación de problemas, el concepto de estado se refiere a una configuración particular o situación específica en la que se encuentra un sistema en un momento dado durante el proceso de resolución de un problema. Un estado es una de las posibles instancias o configuraciones del problema, y se representa mediante un conjunto de variables que describen el sistema en ese instante.

Por ejemplo, en un problema de búsqueda, el estado puede describir la situación actual del entorno, como la ubicación de un agente, la disposición de los objetos, o el valor de las variables relevantes. Los estados se usan en algoritmos de búsqueda para explorar todas las posibles soluciones, donde el objetivo es encontrar una secuencia de acciones que lleve al sistema desde un estado inicial hasta un estado objetivo (solución).

En resumen, el estado es una representación de una situación concreta dentro del proceso de resolución de un problema, que permite evaluar qué acciones se pueden realizar y cómo evolucionará el sistema a través de esos pasos.

Ejemplo:

En un problema clásico como el rompecabezas de 8 piezas (8-puzzle), el estado se define por la disposición de las piezas en la cuadrícula. Cada configuración de las piezas es un estado, y el objetivo es encontrar una secuencia de movimientos (acciones) que transforme el estado inicial en el estado objetivo, que es la disposición correcta de las piezas.

Modelado de problemas mediante espacio de estados

El modelo de problemas mediante espacio de estados es una de las formas más comunes de representar un problema en el campo de la inteligencia artificial y la teoría de la resolución de problemas. En este enfoque, el problema se describe en términos de un espacio de estados, que es el conjunto de todos los estados posibles que el sistema puede alcanzar desde el estado inicial hasta el estado objetivo, mediante una secuencia de acciones.

Componentes principales del modelo de problemas mediante espacio de estados:

1. Estado inicial: Es la situación o configuración en la que comienza el problema. Representa el punto de partida del proceso de resolución.
2. Estado objetivo: Es el estado o la configuración que se desea alcanzar. Este es el objetivo del proceso de resolución.
3. Acciones: Son las operaciones o transformaciones que se pueden realizar desde un estado para generar nuevos estados. Cada acción debe llevar al sistema de un estado a otro, y pueden existir restricciones o reglas que definan qué acciones son válidas en un determinado estado.
4. Espacio de estados: Es el conjunto de todos los posibles estados que se pueden alcanzar desde el estado inicial mediante una secuencia de acciones. El espacio de estados puede representarse de manera gráfica, como un grafo en donde cada nodo es un estado y cada arista representa una acción que lleva de un estado a otro.
5. Función de transición: Es la función que describe cómo las acciones transforman un estado en otro. Dado un estado y una acción, la función de transición determina el siguiente estado al que se llega.
6. Función de coste (opcional): En algunos problemas, cada acción puede tener un coste asociado (por ejemplo, tiempo, distancia, dinero, etc.). La función de coste calcula el coste de aplicar una acción en un estado determinado.

Representación del conocimiento

El Cálculo de Predicados, o Lógica de Primer Orden (LPO), permite hablar de individuos y sus relaciones. El término "Primer Orden" significa que podemos

cuantificar sobre individuos utilizando \forall (para todo) y \exists (existe). Por ejemplo, $\forall x \text{ Hombre}(x) \rightarrow \text{Mortal}(x)$.

El Cálculo de Predicados, o Lógica de Primer Orden (LPO), permite hablar de individuos y sus relaciones. El término "Primer Orden" significa que podemos cuantificar sobre individuos utilizando \forall (para todo) y \exists (existe). Por ejemplo, $\forall x \text{ Hombre}(x) \rightarrow \text{Mortal}(x)$. La Lógica de Segundo Orden permite cuantificar sobre relaciones

Red Semántica:

Es un tipo de estructura de datos que representa el conocimiento en forma de grafos dirigidos, donde los nodos representan conceptos o entidades y los arcos representan relaciones semánticas entre ellos. Estas relaciones pueden ser de diversos tipos, como "es un tipo de", "tiene propiedades", "está relacionado con", entre otros. Las redes semánticas se utilizan en inteligencia artificial (IA) como una forma de organizar y estructurar el conocimiento de manera que sea comprensible tanto para los humanos como para los sistemas informáticos

La Importancia de las Redes Semánticas

Como forma de representación de conocimiento en IA radica en varios aspectos:

Representación estructurada

Las redes semánticas proporcionan una forma estructurada de representar el conocimiento, lo que permite a los sistemas de IA comprender y manipular información de manera más efectiva. Al organizar el conocimiento en forma de grafos con nodos y arcos, se capturan las relaciones semánticas entre conceptos, lo que facilita el razonamiento y la inferencia.

Flexibilidad y expresividad

significa que pueden representar una amplia variedad de relaciones y conceptos de manera intuitiva. Esto permite modelar dominios complejos y capturar información detallada sobre las relaciones entre entidades y conceptos, lo que resulta útil en una variedad de aplicaciones de IA.

Interpretación humana

Debido a su estructura visual e intuitiva, las redes semánticas son fácilmente interpretables por humanos, lo que facilita la colaboración entre humanos y sistemas de IA. Los expertos en dominios específicos pueden utilizar redes semánticas para representar su conocimiento de una manera que sea comprensible para los sistemas informáticos, lo que permite la colaboración y la toma de decisiones informadas.

¿Qué es una red neuronal?

Una red neuronal es un método de la inteligencia artificial (IA) que enseña a las computadoras a procesar datos de una manera similar a como lo hace el cerebro humano. Se trata de un tipo de proceso de machine learning (ML) llamado aprendizaje profundo, el cual utiliza los nodos o las neuronas interconectados en una estructura de capas que se parece al cerebro humano. Crea un sistema adaptable que las computadoras utilizan para aprender de sus errores y mejorar continuamente. De esta forma, las redes neuronales artificiales intentan resolver problemas complicados, como la realización de resúmenes de documentos o el reconocimiento de rostros, con mayor precisión.

¿Por qué son importantes las redes neuronales?

Las redes neuronales pueden ayudar a las computadoras a tomar decisiones inteligentes con asistencia humana limitada. Esto se debe a que pueden aprender y modelar las relaciones entre los datos de entrada y salida que no son lineales y que son complejos. Por ejemplo, pueden realizar las siguientes tareas.

Hacer generalizaciones y sacar conclusiones

Las redes neuronales pueden comprender datos no estructurados y hacer observaciones generales sin un entrenamiento explícito. Por ejemplo, pueden reconocer que dos oraciones de entrada diferentes tienen un significado similar:

¿Puede explicarme cómo hacer el pago?

¿Cómo puedo transferir dinero?

Una red neuronal sabría que ambas oraciones significan lo mismo. O sería capaz de reconocer, en términos generales, que Baxter Road es un lugar, pero que Baxter Smith es el nombre de una persona.

¿Para qué se utilizan las redes neuronales?

Las redes neuronales están presentes en varios casos de uso en muchos sectores, como los siguientes:

- Diagnóstico médico mediante la clasificación de imágenes médicas
- Marketing orientado mediante el filtrado de redes sociales y el análisis de datos de comportamiento
- predicciones financieras mediante el procesamiento de datos históricos de instrumentos financieros
- Previsión de la carga eléctrica y la demanda de energía
- Proceso y control de calidad
- Identificación de compuestos químicos

A continuación, presentamos cuatro de las aplicaciones más importantes de las redes neuronales.

Visión artificial

La visión artificial es la capacidad que tienen las computadoras para extraer información y conocimientos de imágenes y videos. Con las redes neuronales, las computadoras pueden distinguir y reconocer imágenes de forma similar a los humanos. La visión artificial tiene varias aplicaciones, como las siguientes:

Reconocimiento visual en los vehículos autónomos para que puedan reconocer las señales de tráfico y a otros usuarios del camino

Moderación de contenido para eliminar de forma automática los contenidos inseguros o inapropiados de los archivos de imágenes y videos

Reconocimiento facial para identificar rostros y reconocer atributos como ojos abiertos, gafas y vello facial

Etiquetado de imágenes para identificar logotipos de marcas, ropa, equipos de seguridad y otros detalles de la imagen

Reconocimiento de voz

Las redes neuronales pueden analizar el habla humana a pesar de los diferentes patrones de habla, el tono, el idioma y el acento. Los asistentes virtuales como Amazon Alexa y el software de transcripción automática utilizan el reconocimiento de voz para realizar tareas como las siguientes:

Asistir a los agentes de los centros de llamadas y clasificar las llamadas de forma automática

Convertir las conversaciones clínicas en documentación en tiempo real

Subtitular con precisión videos y grabaciones de reuniones para aumentar el alcance del contenido

Procesamiento del lenguaje natural

El procesamiento de lenguaje natural (PLN) es la capacidad de procesar texto natural creado por humanos. Las redes neuronales ayudan a las computadoras a obtener información y significado a partir de los datos y los documentos de texto. El PLN está presente en varios casos de uso, entre los que se incluyen los siguientes:

- Chatbots y agentes virtuales automatizados
- Organización y clasificación automáticas de datos escritos

- Análisis de inteligencia empresarial de documentos con formato largo, como emails y formularios
- Indexación de frases clave que indican sentimientos, como los comentarios positivos y negativos en las redes sociales
- Resumen de documentos y producción de artículos para un tema determinado

Motores de recomendaciones

Las redes neuronales pueden hacer un seguimiento de la actividad del usuario para elaborar recomendaciones personalizadas. También pueden analizar todo el comportamiento de los usuarios y descubrir productos o servicios nuevos que interesen a un usuario específico. Por ejemplo, Curalate, una empresa emergente con sede en Filadelfia, ayuda a las marcas a convertir las publicaciones en las redes sociales en ventas. Las marcas utilizan el servicio de etiquetado inteligente de productos (IPT) de Curalate para automatizar la recopilación y la selección del contenido social que generan los usuarios. El IPT utiliza las redes neuronales para encontrar y recomendar de forma automática productos relevantes para la actividad del usuario en las redes sociales. Los consumidores no tienen que buscar en los catálogos en línea para encontrar un producto específico a partir de una imagen en las redes sociales. En cambio, pueden utilizar el etiquetado automático de productos de Curalate para comprar el producto con facilidad.

¿Cómo funcionan las redes neuronales?

El cerebro humano es lo que inspira la arquitectura de las redes neuronales. Las células del cerebro humano, llamadas neuronas, forman una red compleja y con un alto nivel de interconexión y se envían señales eléctricas entre sí para ayudar a los humanos a procesar la información. De manera similar, una red neuronal artificial está formada por neuronas artificiales que trabajan juntas para resolver un problema. Las neuronas artificiales son módulos de *software*, llamados nodos, y las redes neuronales artificiales son programas de *software* o algoritmos que, en esencia, utilizan sistemas informáticos para resolver cálculos matemáticos.

Arquitectura de una red neuronal simple

Una red neuronal básica tiene neuronas artificiales interconectadas en tres capas:

Capa de entrada

La información del mundo exterior entra en la red neuronal artificial desde la capa de entrada. Los nodos de entrada procesan los datos, los analizan o los clasifican y los pasan a la siguiente capa.

Capa oculta

Las capas ocultas toman su entrada de la capa de entrada o de otras capas ocultas. Las redes neuronales artificiales pueden tener una gran cantidad de capas ocultas. Cada capa oculta analiza la salida de la capa anterior, la procesa aún más y la pasa a la siguiente capa.

Capa de salida

La capa de salida proporciona el resultado final de todo el procesamiento de datos que realiza la red neuronal artificial. Puede tener uno o varios nodos. Por ejemplo, si tenemos un problema de clasificación binaria (sí/no), la capa de salida tendrá un nodo de salida que dará como resultado 1 o 0. Sin embargo, si tenemos un problema de clasificación multiclase, la capa de salida puede estar formada por más de un nodo de salida.

Arquitectura de una red neuronal profunda

Las redes neuronales profundas, o redes de aprendizaje profundo, tienen varias capas ocultas con millones de neuronas artificiales conectadas entre sí. Un número, denominado peso, representa las conexiones entre un nodo y otro. El peso es un número positivo si un nodo estimula a otro, o negativo si un nodo suprime a otro. Los nodos con valores de peso más altos tienen mayor influencia en los demás nodos.

En teoría, las redes neuronales profundas pueden asignar cualquier tipo de entrada a cualquier tipo de salida. Sin embargo, también necesitan mucho más entrenamiento en comparación con otros métodos de *machine learning*. Necesitan millones de ejemplos de datos de entrenamiento en lugar de los cientos o miles que podría necesitar una red más simple.

Mecanismos de búsqueda

Métodos de búsqueda en IA: búsqueda a ciegas, heurística

Tipos de búsquedas en IA

Existen diferentes tipos de búsquedas utilizadas en inteligencia artificial, aprendizaje automático, aprendizaje de refuerzo profundo y redes neuronales. Se suelen dividir en dos categorías: búsquedas no informadas e informadas.

Las búsquedas no informadas son un tipo general de algoritmo que posee muy poca información sobre el estado de la búsqueda. Carecen de información sobre el estado actual, el estado anterior o el estado futuro, y el espacio. También se denomina estado ciego.

Las búsquedas informadas contienen información sobre el objetivo y todas las rutas que lo separan. Otros nombres comunes para las búsquedas informadas son búsqueda heurística, búsqueda de árbol y búsqueda de grafos.

Búsqueda a ciegas o desinformada

Una búsqueda algorítmica de propósito general que funciona según el principio de fuerza bruta. Como se mencionó anteriormente, y por el nombre de la búsqueda, resulta obvio que dicha búsqueda no contiene información adicional sobre el objetivo, la ruta ni nada similar. Las características principales de la búsqueda a ciegas son las siguientes.

No tiene ninguna información sobre el objetivo, por lo que examina cada nodo y consume tiempo para buscar el objetivo.

En una búsqueda a ciegas, no hay información sobre el espacio de búsqueda. El agente crea una ruta para alcanzar el objetivo.

Como no hay información sobre el objetivo, tampoco hay información sobre la ruta entre el punto inicial y el objetivo. Por lo tanto, crean su propia ruta recorriendo cada nodo hasta llegar al nodo final, que es el objetivo final. Una vez alcanzado el objetivo, la búsqueda se detiene.

El proceso de búsqueda a ciegas consume mucho tiempo, ya que deben examinar todos y cada uno de los nodos y, además, no existe el concepto de planificación de rutas en la búsqueda a ciegas.

El único punto positivo de la búsqueda a ciegas es que pueden diferenciar entre el nodo objetivo y el nodo no objetivo.

Tipos de búsquedas a ciegas

Existen diferentes tipos de búsquedas a ciegas, a continuación, se ofrece una breve introducción de cada una.

Búsqueda en amplitud:

Es una estrategia sistemática aplicada en búsquedas. Considera primero todos los nodos en el nivel 1 y, posteriormente, encuentra el objetivo en el nivel 2, encontrando cada nodo. La solución está garantizada en una búsqueda en amplitud. Siempre se busca el objetivo menos profundo, por lo que es la técnica más económica.

Búsqueda de costos uniformes:

Se trata de un tipo de técnica de búsqueda a ciegas. Con un coste uniforme, se puede obtener la solución más económica, ya que manipulan la búsqueda tras

alcanzar cada nodo. No optaron por la técnica más superficial, como en las búsquedas en amplitud.

Búsquedas en profundidad:

Las búsquedas en las que el agente busca el objetivo en profundidad, a diferencia de las búsquedas en amplitud, en las que el agente expande cada nodo y encuentra el objetivo en cada posición, presentan varios problemas: si un árbol tiene muchas profundidades, se vuelve muy laborioso y, al mismo tiempo, confuso y complejo.

Búsqueda de profundidad limitada:

Una técnica híbrida de búsqueda a ciegas. En esta técnica, el agente explora primero las profundidades, pero regresa en cuanto se da cuenta de que, en este camino, no puede encontrar el objetivo y, en cambio, consume tiempo y energía. Por lo tanto, regresa al nivel uno y comienza a expandir el nodo dos en profundidad. Esta técnica es mucho mejor que otras técnicas de búsqueda a ciegas.

Búsquedas de profundización iterativa:

La forma más avanzada de las técnicas de búsqueda a ciegas. En las búsquedas limitadas en profundidad, no existe un parámetro claro para determinar en qué punto se debe haber explorado la profundidad. En esta técnica, existe un límite hasta el cual se puede expandir un nodo para encontrar el objetivo.

Búsquedas heurísticas o informadas

Las búsquedas informadas son aquellas en las que se encuentran soluciones óptimas. En estas búsquedas, también existen espacios. La heurística asigna los valores de los números reales a los nodos, y las ramas y el espacio proporcionan la solución al modelo para obtener la búsqueda en esa área específica. Algunas de las características principales de las búsquedas heurísticas son las siguientes.

Da una solución real y posible.

La solución puede tener la forma de un punto o de un espacio de estados.

También son capaces de proporcionar la ruta desde la posición inicial hasta la posición final, meta o destino.

Es rápido y económico en comparación con las búsquedas a ciegas.

También proporciona retroalimentación al modelo.

La heurística definida para cada nodo, rama y objetivo depende del usuario.

Tipos de búsquedas heurísticas

Existen dos tipos de búsquedas heurísticas en inteligencia artificial, estas son

1) Búsquedas en profundidad

2) Búsquedas en amplitud.

Ahora bien, surge la pregunta de si ambos métodos también se utilizan en búsquedas a ciegas. Estas búsquedas heurísticas cuentan con una planificación de ruta adecuada, heurísticas asignadas e información sobre el objetivo a alcanzar, lo que las diferencia y las hace más eficientes que las que se describen en las búsquedas a ciegas. Estas ofrecen mejores soluciones que las que se utilizan en búsquedas a ciegas.

El algoritmo minimax es un algoritmo de toma de decisiones utilizado en teoría de juegos e inteligencia artificial para determinar la mejor jugada para un jugador en una situación en la que el otro jugador también juega de forma óptima. Este algoritmo se utiliza habitualmente en juegos de suma cero para dos jugadores, como ajedrez, tres en raya y Go.

Cómo funciona

El algoritmo comienza en el estado actual del juego y genera todos los posibles estados subsiguientes simulando todos los movimientos posibles de ambos jugadores. Para cada uno de esos estados, genera de nuevo todos los posibles estados subsiguientes, y así sucesivamente, hasta llegar a un estado terminal/nodo hoja (p. ej., victoria, derrota, empate) o alcanzar la profundidad de búsqueda máxima.

El algoritmo asigna una puntuación a cada nodo terminal/hoja, generalmente +1 para una victoria, 0 para un empate y -1 para una derrota. Luego, propaga estas puntuaciones a través del árbol de juego utilizando la regla minimax: para un nodo max (que representa la jugada del jugador actual), la puntuación es la máxima de las puntuaciones de sus hijos, y para un nodo min (que representa la jugada del oponente), la puntuación es la mínima de las puntuaciones de sus hijos.

Luego, el algoritmo elige el movimiento que conduce al estado con el puntaje más alto para el máximo de nodos y el puntaje más bajo para el mínimo de nodos, considerando que el oponente jugará de manera óptima.

alfa-beta es una técnica utilizada para mejorar la eficiencia del algoritmo minimax en la IA de videojuegos. Esta técnica se basa en la observación de que, en muchos juegos, algunas ramas del árbol de juego pueden podarse (ignorarse) con seguridad, ya que se garantiza que son peores que otras.

Explicación más técnica (valores alfa-beta)

El algoritmo utiliza dos parámetros, alfa (mejor valor para el jugador que maximiza) y beta (mejor valor para el jugador que minimiza).

El algoritmo comienza con alfa y beta con valores de infinito negativo y positivo, respectivamente. Cabe destacar que estos son los peores valores posibles: alfa aumentará y beta disminuirá.

A medida que el algoritmo evalúa cada nodo, compara su puntuación con los valores alfa y beta actuales. Si el valor alfa actual es mayor que el valor beta actual, significa que la rama actual es peor que una rama ya evaluada y puede podarse sin problemas.

Lips y Prolog

Características de LISP:

Características del lenguaje de programación LISP:

Es un lenguaje de programación independiente de la máquina.

Emplea un proceso de diseño iterativo y es fácilmente ampliable.

Nos permite construir y actualizar dinámicamente programas y aplicaciones.

Tiene una función de depuración de alto nivel.

Se admite la programación orientada a objetos.

Es un lenguaje basado en expresiones.

Se puede utilizar para respaldar una variedad de afirmaciones de toma de decisiones, incluidas las de tipo si, cuándo, caso y condición.

Se admitirán diferentes declaraciones iterativas, como do, loop, loopfor, dotimes y dolist.

También podemos escribir nuestras propias funciones en Lisp.

Listas en LISP:

Listas de uso común en LISP no son más que una lista enlazada simple. Las listas en LISP se estructuran como una serie de registros. El concepto de Cons es crucial al analizar las estructuras de registros en LISP. Cons es una

estructura de registro en LISP con dos componentes principales. Cons toma dos argumentos y devuelve una nueva celda con los valores car y dir.

- coche : en una función cons, se utiliza para obtener el primer valor.
- cdr : se utiliza para obtener el segundo valor de la función cons.

Los valores se escriben como un par de puntos contenidos entre paréntesis si el segundo valor no es nulo o simplemente otra celda constante.

La función de lista acepta cualquier número de parámetros.

Aplicaciones de LISP:

La esencia de LISP son los símbolos, las expresiones simbólicas y la computación con ellos.

El álgebra computacional, la demostración de teoremas, los sistemas de planificación, los diagnósticos, los sistemas de reescritura, la representación y el razonamiento del conocimiento, los lenguajes lógicos, la traducción automática, los sistemas expertos y más son ejemplos de temas de IA típicos para la computación con símbolos.

Las aplicaciones de IA famosas escritas en LISP son:

- Macsyma, el primer gran sistema de álgebra computacional, se implementó en LISP y es una aplicación de IA muy conocida en estas disciplinas.
- ACL2 es un demostrador de teoremas popular que utilizan empresas como AMD.
- El ejército estadounidense utilizó DART como planificador logístico durante la primera Guerra del Golfo.
- Se dice que este programa LISP compensó todo el gasto en investigación en inteligencia artificial de Estados Unidos en ese momento.
- El Asistente del Autorizador de American Express, que verifica las transacciones con tarjetas de crédito.

Extensión de archivo:

Archivo de código fuente escrito en Lisp, un lenguaje de programación con numerosos dialectos como Common Lisp y Scheme; incluye código de programa de texto simple que se ejecuta con un intérprete Lisp; tal vez un programa completo o una parte de una aplicación Lisp más grande.

Archivo .LSP

Los archivos LSP también pueden incluir un componente de una aplicación o incluso la aplicación completa, y el formato LSP admite numerosos formatos, incluido Scalar. Los archivos LSP se pueden leer y visualizar con cualquier editor

de texto; sin embargo, se prefieren los editores con resaltado de sintaxis Lisp, ya que son más fáciles de abrir y visualizar. El procesamiento simbólico, la inteligencia artificial y el procesamiento del lenguaje natural se benefician enormemente de los archivos LSP.

Aplicaciones que abren un archivo .LSP:

Bloc de notas de Microsoft

Microsoft WordPad

Edición de texto de Apple

Ventajas:

El lenguaje que es a la vez bello y fuerte

La versatilidad que ofrecen la homoiconicidad, las macros y la reflexión es inmensa.

Obtendrás un rendimiento fantástico si usas algo como SBCL.

Los programadores pueden usar Lisp para desarrollar aplicaciones más rápidas. Desarrollar en menos tiempo y ejecutarse con mayor rapidez.

El estado actual de la investigación Lisp en bioinformática y biología computacional sugiere que en breve podría surgir una comunidad BioLisp.

Desventajas:

Los desarrolladores de Lisp tienen escasez de oportunidades laborales

A muchas personas les desagrada el ecosistema relativamente pequeño en comparación con el de la sintaxis de Java, Python, JavaScript y C++.

Cuesta un poco acostumbrarse a la notación de prefijos y a las montañas de paréntesis.

No existe tal cosa como un ecosistema Common Lisp.

El idioma está congelado/muerto

Características de PROLOG:

PROLOG es un lenguaje de programación declarativo.

Utiliza terminología de cálculo de predicados.

PROLOG es un manejador natural de listas y recursiones.

Este lenguaje tiene un motor de inferencia incorporado, así como retroceso automático.

PROLOG tiene paralelismo incorporado.

Unificación: El concepto principal es ver si las frases pueden combinarse para reflejar la misma estructura.

Para problemas que requieren inferencia, PROLOG permite una codificación muy eficiente.

Las aplicaciones de PROLOG son las siguientes:

Lenguaje de especificación

Planificación de robots

Comprensión del lenguaje natural

Aprendizaje automático

Resolución de problemas

Recuperación inteligente de bases de datos

Sistema experto

Razonamiento automatizado

Desventajas:

En general, LISP ofrece capacidades de E/S superiores a PROLOG.

PROLOG no suele ser compatible con gráficos. Turbo PROLOG, recién lanzado, es una excepción.

La secuencia de introducción de reglas tiene un impacto significativo en la eficiencia de PROLOG. El orden de las funciones LISP tiene un impacto insignificante en la eficiencia del lenguaje.

PROLOG y LISP se pueden combinar. Algunas aplicaciones de IA se adaptan mejor a LISP, mientras que otras lo hacen a PROLOG. La mejor configuración podría ser un sistema híbrido que combine ambos lenguajes. Esta combinación puede realizarse de dos maneras diferentes.

Otros lenguajes

Apoyo al aprendizaje para principiantes	Python cuenta con un sólido apoyo de la comunidad y ha existido durante décadas, por lo que hay muchos tutoriales y soporte disponibles.	R cuenta con un fuerte apoyo de la comunidad y ha existido durante décadas, por lo que hay muchos tutoriales y soporte disponibles.	Julia todavía es relativamente nueva, por lo que los tutoriales, si bien están disponibles, pueden no ser tan abundantes como los de Python o R.
--	--	---	--

Argumento clave de venta	Uno de los lenguajes de programación más populares; soporte robusto para aprendizaje automático e IA; también se utiliza en otros sectores como seguridad de la información, juegos y desarrollo web.	Soporte sólido para tareas de minería de datos, análisis estadístico y numérico; conocido como la mejor alternativa a SAS , SPSS y Stata ; comúnmente utilizado en el ámbito académico.	Diseñado para ciencia de datos y ML; gran legibilidad de código; mejor velocidad que Python y R.
---------------------------------	---	--	--

TensorFlow y PyTorch tienen diferentes filosofías de diseño que afectan la forma en que escribes y ejecutas tu código. TensorFlow se basa en un gráfico computacional estático, lo que significa que defines la estructura y las operaciones de tu modelo antes de ejecutarlo. PyTorch, por otro lado, se basa en un gráfico computacional

dinámico, lo que significa que puede modificar su modelo sobre la marcha a medida que lo ejecuta. Esto proporciona a PyTorch más flexibilidad e interactividad, pero también requiere más depuración y pruebas. TensorFlow, por el contrario, es más estable y escalable, pero también menos intuitivo y expresivo.

¿Qué es el aprendizaje supervisado?

El aprendizaje supervisado requiere datos de entrada y salida etiquetados durante la fase de entrenamiento del ciclo de vida del machine learning. Estos datos a menudo son etiquetados por un científico de datos en la fase de preparación - una de las tareas que hace un data scientist - antes de usarse para entrenar y probar el modelo.

Se llama aprendizaje supervisado porque al menos parte de este modelo requiere supervisión humana. La gran mayoría de los datos disponibles son datos brutos sin etiquetar. Por lo general, se requiere la interacción humana para etiquetar con precisión los datos. Naturalmente, puede ser un proceso intensivo en recursos, ya que se necesitan grandes conjuntos de datos etiquetados.

Los modelos predictivos también se entrenan con técnicas de aprendizaje automático supervisado. Mediante el aprendizaje de patrones entre los datos de entrada y salida, los modelos de aprendizaje supervisado pueden predecir resultados a partir de datos nuevos e invisibles. Esto podría ser en la previsión de cambios en los precios de la vivienda o en las tendencias de compra de los clientes, por ejemplo.

El aprendizaje supervisado se utiliza para:

- Clasificar diferentes tipos de archivos como imágenes, documentos o palabras escritas.

- Pronosticar tendencias y resultados futuros a través de patrones en los datos.

¿Qué es el aprendizaje no supervisado?

El aprendizaje no supervisado es el entrenamiento de modelos de datos sin procesar y sin etiquetar. Como el nombre indica, el aprendizaje automático no supervisado no necesita tanta intervención humana comparado con el aprendizaje supervisado. Una persona tiene que establecer los parámetros del modelo, como la cantidad de puntos de clúster, pero el modelo es capaz de procesar grandes conjuntos de datos de manera efectiva y sin supervisión humana.

El aprendizaje automático no supervisado se utiliza principalmente para:

Clústers de datos con similitudes entre características o datos de segmento

Entender la relación entre diferentes puntos de datos, como recomendaciones de música automatizadas

Realizar análisis de datos iniciales

Aprendizaje supervisado y no supervisado diferencias

La principal diferencia entre el aprendizaje supervisado y el no supervisado es la necesidad de datos etiquetados. El machine learning supervisado se basa en datos de entrada y salida etiquetados, mientras que el aprendizaje no supervisado procesa datos sin etiquetar o sin procesar.

Hay otras diferencias, que son las siguientes:

La necesidad de datos etiquetados en el aprendizaje automático supervisado.

El modelo que se utiliza para solucionar un problema. El aprendizaje automático supervisado generalmente se usa para clasificar datos o hacer predicciones, mientras que el aprendizaje no supervisado generalmente se usa para comprender las relaciones dentro de los conjuntos de datos.

El aprendizaje automático supervisado requiere muchos más recursos debido a la necesidad de datos etiquetados.

¿Qué es el aprendizaje automático?

Definición de aprendizaje automático: Una aplicación de inteligencia artificial con algoritmos que analizan datos, que aprenden de dichos datos y que, en última instancia, aplican lo aprendido para tomar decisiones fundamentadas.

¿Qué es el aprendizaje profundo?

Definición de aprendizaje profundo: Un subcampo del aprendizaje automático que estructura algoritmos en niveles para crear una “red neuronal artificial” capaz de aprender y tomar decisiones inteligentes por sí misma.

La diferencia entre el aprendizaje automático y el aprendizaje profundo

En la práctica, el aprendizaje profundo es solo un subconjunto del aprendizaje automático. De hecho, el aprendizaje profundo técnicamente es aprendizaje automático y funciona de una manera similar, de ahí que los términos a veces se intercambien sin excesivo rigor. No obstante, sus capacidades son diferentes.

Si bien los modelos básicos de aprendizaje automático mejoran constantemente en el desempeño de sus funciones específicas a medida que incorporan nuevos datos, siguen necesitando intervención humana de un modo u otro. Si un algoritmo de IA produce una predicción inexacta, entonces un ingeniero tiene que intervenir y hacer ajustes. Con un modelo de aprendizaje profundo, un algoritmo puede determinar si una predicción es acertada o no valiéndose de su propia red neuronal, sin necesidad de ayuda humana.

Sistemas expertos

¿Qué son los sistemas expertos?

Los sistemas expertos (SE) son programas informáticos que tienen el objetivo de solucionar un problema concreto y utilizan la Inteligencia Artificial (IA) para simular el razonamiento de un ser humano. Se denominan sistemas *expertos* porque estos programas imitan la toma de decisiones de un profesionalista en la materia.

Actualmente, se consideran dentro del global de la Inteligencia Artificial. Se crearon durante la década de los 60 (aunque alcanzaron su mayor popularidad en los años posteriores) y fueron uno de los primeros sistemas de Inteligencia Artificial utilizados con éxito.

Si te interesan los distintos usos de los sistemas de inteligencia artificial en todas sus formas, en la Maestría en Inteligencia Artificial online de UNIR México encontrarás los conocimientos técnicos y prácticos necesarios para lograr el comportamiento inteligente de las máquinas.

Aplicaciones en la toma de decisiones

La toma de decisiones es el proceso de realizar elecciones identificando una decisión, recopilando información y evaluando resoluciones alternativas.

Utilizar un proceso de toma de decisiones paso a paso puede ayudarle a tomar decisiones más deliberadas y reflexivas al organizar la información relevante y definir alternativas. Este enfoque aumenta las probabilidades de elegir la alternativa más satisfactoria posible.

Paso 1: Identificar la decisión

Te das cuenta de que necesitas tomar una decisión. Intenta definir claramente la naturaleza de la decisión que debes tomar. Este primer paso es muy importante.

Paso 2: Recopilar información relevante

Reúne información pertinente antes de tomar una decisión: qué información necesitas, cuáles son las mejores fuentes de información y cómo obtenerla. Este paso implica trabajo interno y externo. Parte de la información es interna: la buscarás mediante un proceso de autoevaluación. Otra información es externa: la encontrarás en línea, en libros, de otras personas y de otras fuentes.

Paso 3: Identificar las alternativas

A medida que recopile información, probablemente identificará varias posibles vías de acción o alternativas. También puede usar su imaginación e información adicional para construir nuevas alternativas. En este paso, enumerará todas las alternativas posibles y deseables.

Paso 4: Sopesar la evidencia

Utiliza tu información y emociones para imaginar cómo sería si llevaras a cabo cada una de las alternativas hasta el final. Evalúa si la necesidad identificada en el Paso 1 se satisfaría o resolvería con cada alternativa. A medida que avances en este difícil proceso interno, comenzarás a favorecer ciertas alternativas: aquellas que parecen tener mayor potencial para alcanzar tu objetivo. Finalmente, ordena las alternativas según tu propio sistema de valores.

Paso 5: Elige entre alternativas

Una vez que haya evaluado toda la evidencia, estará listo para seleccionar la alternativa que le parezca más adecuada. Incluso puede optar por una combinación de alternativas. Es muy probable que su elección en el paso 5 sea igual o similar a la alternativa que encabezó su lista al final del paso 4.

Paso 6: Tomar acción

Ahora está listo para tomar alguna acción positiva y comenzar a implementar la alternativa que eligió en el Paso 5.

Paso 7: Revisa tu decisión y sus consecuencias

En este último paso, considere los resultados de su decisión y evalúe si ha resuelto la necesidad identificada en el Paso 1. Si la decisión no la ha satisfecho, puede repetir ciertos pasos del proceso para tomar una nueva decisión. Por ejemplo, podría recopilar información más detallada o ligeramente diferente, o explorar alternativas adicionales.

```
import cv2

import torch

from deep_translator import GoogleTranslator


model = torch.hub.load('ultralytics/yolov5', 'yolov5s')


# Cargar la imagen

image_path = 'imagen.jpg'

image = cv2.imread(image_path)


# Realizar la detección de objetos

results = model(image)


# Obtener los nombres de los objetos detectados

objects_detected = results.pandas().xyxy[0]['name'].tolist()


# Traducir los nombres al español

translator = GoogleTranslator(source='en', target='es')

objects_translated = [translator.translate(obj) for obj in objects_detected]


# Mostrar los objetos detectados en español

print("Objetos detectados en español:", objects_translated)
```

<https://www.wingsoft.com/blog/historia-de-la-ia>

<https://cloud.google.com/learn/what-is-artificial-intelligence?hl=es-419>

<https://sistemasinformatica.istmo.tecnm.mx/cursos/inteligencia-artificial/2-representacion-del-conocimiento/2-4-redes-semanticas/>

<https://aws.amazon.com/es/what-is/neural-network/#:~:text=Las%20redes%20neuronales%20ayudan%20a,y%20clasificaci%C3%B3n%20autom%C3%A1ticas%20de%20datos>